GSLC Deep Learning

Nama: Billie Godwin
NIM: 2802392816

BAGIAN A:

1. Batch Normalization menormalisasikan aktivasi menggunakan rata rata dan varian mini batch, karena statistik tersebut berubah antar mini bach, maka nilai aktivasi yang diterima model mengandung bariasi stokastik. Variasi ini dapat bertindak sebagai regularisasi ringan sehingga model tidak terlalu bergantung pada pola spesifik data pelatihan (loffe & Szegedy, 2015). Untuk bagian "Menghilangkan Dropout", Dropout masih dapat berguna pada model dengan dataset yang sangat kecil, kapasitas tinggi, *overfitting* yang berlebihan. Menghilangkan Dropout dapat membuat Batch Normalization menjadi tidak stabil ketika ukuran batch sangat kecil, distribusi batch tidak merata, atau statistik pelatihan berbeda dari distribusi inferensi.

Referensi: Sesi 5, Slide 6-8; loffe dan Szegedy (2015).

2. Pada *plain* CNN, penambahan lapisan memungkinkan model untuk merepresentasikan fungsi yang sama dengan jaringan lebih dangkal melalui *identity mapping* (Secara teori). Tetapi representasi tersebut tidak bisa menjadi patukan optimisasi berhasil. Jaringan yang lebih dalam bisa menjadi lebih sulit dilatih karena gradien melemah atau membesar selama propagasi balik, sementara komposisi banyak lapisan memberi efek sebaliknya pada optimasi sehingga makin kompleks. Akibatnya, akurasi pelatihan dapat menurun meskipun kapasitas model bertambah. Gradien terhadap input memuat komponen langsung dari jalur identitas. Jalur tersebut membantu pertahankan aliran gradien dan mempermudahkan optimasi. Mekanisme ini merupakan fondasi ResNet (He et al., 2016).

Referensi: Sesi 5, slide 10-12; Sesi 2, slide 5-12; He et al. (2016).

3. *Feature Extraction* membekukan semua *backbone pretrained* dan hanya melatih *classifier* baru. Pada ResNet-18 dengan 10 kelas, jumlah parameter yang diperbarui sekitar 5130 dari total 11181642 parameter. Dengan cara tersebut hanya membutuhkan komputasi yuang lebih rendah dan umumnya lebih aman ketika data berlabel terbatas. *Fine Tuning* membuka sebagian atau semua backbone sehingga dapat disesuaikan dengan domain target. Namun membutuhkan lebih banyak kekuatan komputasi, memori, serta pengaturan learning rate yang harus lebih diperhatikan. Sehingga *Feature Extraction* lebih sesuai menjadi baseline ketika domain target mirip ImageNet dan data terbatas, sedangkan *Fine Tuning* lebih sesuai ketika fitur bawaan belum memadai dan tersedia data validasi untuk mengontrol adaptasi.

Referensi: Sesi 5, slide 14-16 dan 27-29.

4. Data Augmentation diterapkan dalam *training set* untuk menghasilkan variasi input dan mengurangi kebiasaan model untuk menghafal citra tertentu. Namun sebaliknya, validasi dan tes set harus menggunakan transformasi yang deterministik agar semua model dapat dievaluasi pada distribusi input yang konsisten. Augmentasi acak dapat menyebabkan skor berubah dan menyulitkan perbandingan yang adil. Contohnya pada klasifikasi ras hewan perliharaan, *vertical flip* berpotensi tidak layak apabila menghasilkan orientasi hewan yang tidak realistis. Transformasi tersebut dapat mengubah konteks visual dan orientasi objek secara berlebihan tanpa memberikan variasi yang representatif terhadap kondisi penggunaan yang sebenarnya. Namun, kelayakannya harus ditentukan berdasarkan karakteristik dataset dan invariansi dari tabel.

Referensi: Sesi 5, slide 20-22; Sesi 2, slide 23-24.

5. *Catastrophic Forgetting* terjadi ketika pembaruan parameter selama Fine Tuning dilakukan secara terlalu agresif sehingga representasi yang sudah dipelajari dari dataset pretrained mengalami perubahan yang besar. Sehingga akibatnya model dapat kehilangan fitur visual umum yang sebelumnya berguna dan malah justru mengalami penurunan kemampuan generalisasi. Strategi pertama adalah *differential learning rate*, dimana classifier baru menggunakan *learning rate* yang lebih tinggi, sedangkan *backbone* menggunakan *learning rate* yang lebih rendah. Strategi kedua adalah *gradual unfreezing*, yaitu membuka blok terdalam terlebih dahulu sebelum membuka lapisan yang lebih awal. Kedua strategi ini perlu digabungkan dengan pemantauan *validation loss*, *checkpoint* model terbaik, serta penghentian dini.

Referensi: Sesi 05, slide 27-29.

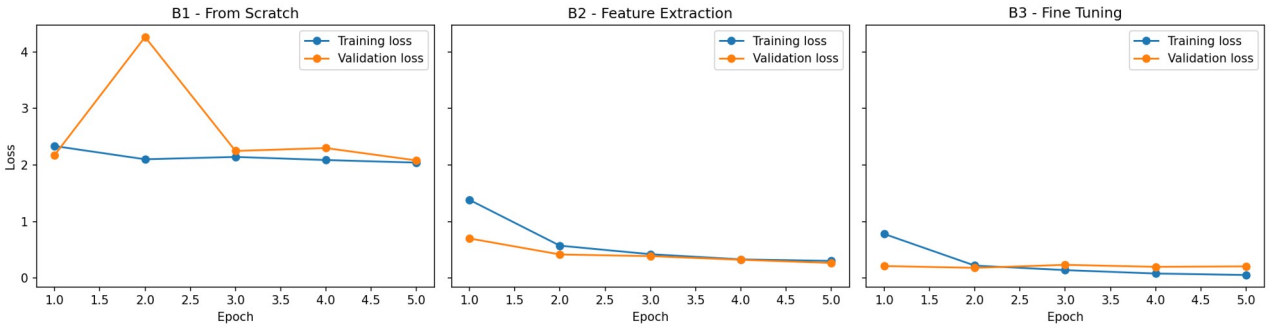
Referensi Ilmiah untuk Bagian A:
- Ioffe, S., & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. Proceedings of ICML.
- He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep Residual Learning for Image Recognition. Proceedings of CVPR.

BAGIAN C:

1.

code	strategy	trainableParams	totalParams	learningRates	epochsRun	bestEpoch	trainTime_s	trainAcc	valAcc	overfitGap	testAcc	testMacroF1
B1	From Scratch	11181642	11181642	0.001	5	5	79.5	0.2395	0.2054	0.0342	0.2383	0.2402
B2	Feature Extraction	5130	11181642	0.001	5	5	75.3	0.9423	0.936	0.0063	0.9195	0.9193
B3	Fine Tuning	8398858	11181642	0.0001 / 0.001	5	2	73.8	0.974	0.9596	0.0144	0.9329	0.9327
B4	Fine Tuning (No Augmentation)	8398858	11181642	0.0001 / 0.001	5	4	52.8	1	0.9495	0.0505	0.943	0.9431

Berdasarkan dari hasil data tersebut, model B4 memperoleh Macro F1 yang tertinggi, yaitu disekitar 0,9431. Namun, model B3 memiliki *validation accuracy* tertinggi sekitar 95,96%. Perbedaan ini menunjukkan bahwa model terbaik berdasarkan validasi tidak selalu sama dengan model yang menghasilkan metrik tes tertinggi.



a. B1: *Training Loss* menurun secara terbatas, sedangkan *Validation Loss* melonjak hingga 4,26 pada epoch kedua sebelum kembali turun.
b. B2: *Training Loss* dan *Validation Loss* menurun secara relatif konsisten.
c. B3: *Training Loss* turun tajam, sementara *Validation Loss* mencapai nilai terendah pada epoch kedua lalu meningkat sedikit.

2.
a. B1 mendapatkan akurasi tes sebesar 23,83% dan Macro F1 24,02%, jauh di bawah B2 (91,93%) dan B3 (93,27%). Hal ini menunjukkan keunggulan *Transfer Learning* pada data terbatas. B1 harus mempelajari 11,18 juta parameter visual dengan inisialisasi acak, sedangkan B2 dan B3 memanfaatkan fitur *pretrained* ImageNet yang disesuaikan untuk klasifikasi kucing dan anjing. Hasil ini dapat dikaitkan dengan Sesi 5, slide 14 dan 16.

b. B2 hanya memperbarui 5130 parameter dengan Macro F1 91,93%, sedangkan B3 memperbarui 8398858 parameter dan mendapatkan hasil 93,27%. Artinya, *Fine Tuning* blok terakhir dapat meningkatkan performa, tetapi kenaikannya relatif kecil dibandingkan jumlah parameter yang diperbarui. B2 cocok untuk kesederhanaan dan biaya pembaruan yang rendah, sedangkan B3 lebih sesuai jika peningkatan performa diperlukan. Hasil ini dapat dikaitkan dengan Sesi 5, slide 16.

c. B3 menggunakan augmentasi, sedangkan B4 tidak. B4 mencapai akurasi training 100%, validasi 94,95%, dan Macro F1 tes 94,31%, dengan *generalization gap* 5,05 poin, lebih besar daripada B3 (1,44 poin). Hasil ini menandakan bahwa tanpa augmentasi, model lebih kemungkinan *overfitting*. Hasil ini dapat dikaitkan dengan Sesi 5, slide 20.

3.



Pola Kesalahan yang Terlihat:
1. Ketika visual memiliki kemiripan, seperti pola bulu, warna, moncong, struktur wajah, sudut pengambilan, bagian tubuh terpotong, pencahayaan tidak merata, serta ukuran objek yang kecil juga ikut berpengaruh.
2. Beberapa prediksi salah memiliki *confidence* yang tinggi, semisalkan 96% pada citra *Beagle* yang diprediksi sebagai *American Pit Bull Terrier.* Ini menunjukkan kalau *confidence* tinggi tidak menjamin prediksi tersebut benar.

4. Rekomendasi Implementasi Industri:
1. **Mulai dari *Feature Extraction*** (B2 menjadi *baseline* efisien dengan 5130 parameter dan Macro F1 91,93%).
2. **Pertimbangkan *Fine Tuning*** (B3 meningkatkan Macro F1 sebesar 1,34% dibandingkan B2).
3. **Evaluasi Augmentasi** (B4 memiliki skor tertinggi, namun *generalization gap* terbesar).
4. **Gunakan *Checkpointing* dan *Early Stopping*.**
5. **Audit Kesalahan.**

Batasan Penelitian:
Eksperimen ini menggunakan satu random seed (42), data dan kelas terbatas, serta satu lingkungan komputasi. Validitas perbandingan B3 dan B4 juga bergantung pada kesetaraan inisialisasi dan pelatihan.

Repositori GitHub: https://github.com/GodwinCB/GSLC-Deep-Learning.git

Pernyataan Penggunaan AI

Saya menggunakan ChatGPT (OpenAI – Luna 6, maaf kurang tau karena *free version*) dan Claude (Anthropic – Sonnet 5.5) sebagai alat bantu untuk memahami logika kode, alur logika, cara pemakaian kode snippet, dan pengecekan akhir kode (Claude). Serta mempelajari materi dan mencari referensi makalah yang dibutuhkan (ChatGPT).